Centro de e-Learning

UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Proyecto Final: Predicción de índices de calidad del aire (AQI) para distintas estaciones de monitoreo en Delhi

Integrantes grupo 8:

Andrea Saad

Patricia Blua

Laura Gómez

María Josefina Serio

Bianca Ricciardi

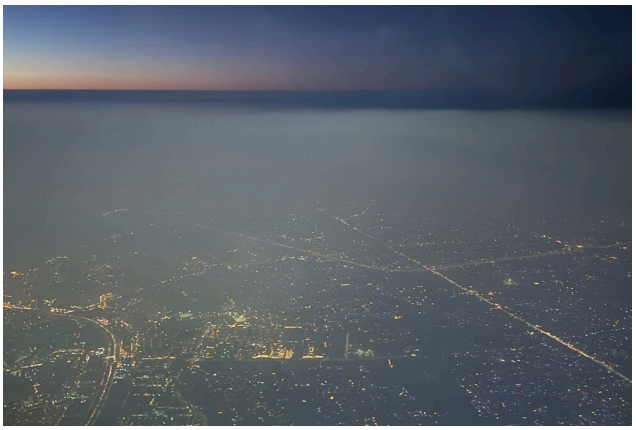

Una capa de niebla y contaminación se ve sobre Nueva Delhi, vista desde la ventana de un avión, en Nueva Delhi, el sábado 25 de octubre de 2025. (AP Foto/Yirmiyan Arthur)

Fecha de entrega: 31-Mar-2026

Diplomatura en Ciencia de Datos y Análisis Avanzado – UTN

Resumen Ejecutivo

La calidad del aire (AQI) representa uno de los principales desafíos ambientales y sanitarios en grandes ciudades, especialmente en contextos urbanos altamente contaminados como Delhi (Territorio de la Capital Nacional de Delhi, estado de la India). Anticipar episodios críticos de baja calidad de AQI es esencial para proteger la salud pública y orientar políticas preventivas.

Este proyecto consiste en predecir el AQI a partir de datos horarios de clima y contaminantes de seis estaciones de monitoreo de Delhi, abordando el problema tanto desde la clasificación (categoría sanitaria) como desde la regresión (valor numérico de AQI). La metodología sigue el marco CRISP-DM.

El Análisis Exploratorio de Datos (EDA) permitió identificar una duplicación de los datos en las estaciones de monitoreo, lo que invalidaba un enfoque espacial tradicional. En función de este hallazgo, se estableció como eje central el régimen de contaminación, segmentando los datos en escenarios normales (AQI ≤ 150) y críticos (AQI > 150). Se incorporaron rezagos horarios del AQI (1, 6 y 24 horas) para capturar la autocorrelación del fenómeno. Se evaluaron Regresión Lineal, Regresión Logística, Random Forest, XGBoost, DNN y LSTM.

Los rezagos horarios resultaron ser las **features de mayor importancia relativa**. En **clasificación**, XGBoost lideró en los segmentos global y normal (F1-score ponderado > 0.975 y AUC-ROC ≈ 1) y RF en el segmento crítico (F!-score = 0.9822 y AUC-ROC $\approx 1,0$). En **regresión,** la regresión lineal obtuvo el mejor desempeño en los segmentos global y crítico, (RMSE ≈ 7,1 y 8,8 y; R^2 > 0,99), mientras que XGBoost fue el modelo más preciso en el régimen normal (RMSE ≈ 3,1; R^2 ≈ 0,98). Los modelos LSTM, pese a su mayor complejidad, no lograron superar a los enfoques clásicos.

El impacto esperado es la mejora de los sistemas de alerta temprana de calidad del aire, con modelos precisos, interpretables y de bajo costo computacional, escalables a otras ciudades. Los resultados aportan valor directo a organismos de salud pública, sistemas de monitoreo ambiental y equipos de gestión urbana que requieren decisiones basadas en evidencia ante episodios críticos de contaminación.

Definición del Problema y Relevancia

La contaminación del aire es uno de los principales problemas ambientales y sanitarios en contextos urbanos densamente poblados. En ciudades como Delhi, los elevados niveles de polución afectan de manera directa la salud pública, incrementando la incidencia de enfermedades respiratorias y cardiovasculares, además de generar impactos económicos asociados a la atención médica, la reducción de la productividad y las restricciones en la movilidad urbana. En este contexto, el Índice de Calidad del Aire (Air Quality Index, AQI) se presenta como un indicador clave para comunicar el nivel de riesgo ambiental y orientar decisiones preventivas.

El problema abordado en este proyecto consiste en predecir el nivel de AQI de forma anticipada y confiable, tanto en términos de su valor numérico como de la categoría sanitaria asociada. La predicción temprana del AQI permitirá mejorar los sistemas de alerta, optimizar la planificación de políticas públicas y reducir el impacto negativo de los episodios críticos de contaminación sobre la población.

Como objetivos específicos se plantean: realizar un análisis exploratorio exhaustivo de los datos; diseñar un proceso de preprocesamiento e ingeniería de variables que capture la dinámica temporal del fenómeno; comparar distintos algoritmos de clasificación y regresión; y seleccionar los modelos con mejor desempeño y mayor robustez.

Desde una perspectiva estratégica, el proyecto es relevante porque demuestra cómo el uso de técnicas de la ciencia de datos puede transformar grandes volúmenes de datos ambientales para anticipar escenarios críticos de contaminación. La información obtenida tiene valor tanto para organismos públicos como para sistemas de monitoreo ambiental, contribuyendo a decisiones basadas en evidencia y a una gestión más eficiente del riesgo ambiental, generando un impacto real en la prevención de la salud de la población y en los recursos urbanos.

Datos y Metodología

El análisis se desarrolló a partir de un dataset público obtenido de Kaggle, correspondiente a datos horarios de clima y contaminación atmosférica de la ciudad de Delhi para el año 2025 (https://www.kaggle.com/datasets/sohails07/delhi-weather-and-aqi-dataset-2025).

El conjunto de datos original contiene 52.560 registros, provenientes de seis estaciones de monitoreo, e incluye variables meteorológicas (temperatura, humedad, presión atmosférica, velocidad del viento) y contaminantes clave: partículas en suspensión (PM2.5, PM10), monóxido de carbono (CO) y dióxido de nitrógeno (NO2), junto con el valor del AQI.

El Análisis Exploratorio de Datos (EDA) permitió evaluar la calidad del dataset y comprender su estructura. Entre los principales hallazgos se identificó que las estaciones de monitoreo se agrupan en dos conjuntos con estadísticas descriptivas idénticas y correlación perfecta, lo que sugiere una duplicación de señales en la fuente de datos (Graf. 1). Este resultado invalidó un enfoque de modelado por estación y motivó un rediseño metodológico, seleccionando una estación representativa por grupo y redefiniendo el problema desde una perspectiva de régimen de contaminación.

El preprocesamiento incluyó la eliminación de variables sin aporte predictivo, como ID, latitud, longitud de ubicación de las estaciones y la normalización de variables numéricas. El AQI de Delhi llega a valores extremos (Graf. 3), por lo que se escaló tanto X como Y con StandardScaler independientes. Asimismo, se realizó una ingeniería de variables temporales, incorporando información de hora del día, día de la semana y mes, junto con rezagos temporales del AQI (lags de 1, 6 y 24 horas), con el objetivo de capturar la fuerte autocorrelación temporal del fenómeno.

La metodología general del proyecto se enmarca en el enfoque CRISP-DM, siguiendo las etapas de comprensión del negocio, comprensión de los datos, preparación de los datos, modelado, evaluación y análisis de resultados.

Modelado y Evaluación

Para abordar la predicción del AQI, se implementaron dos enfoques complementarios: clasificación, orientada a predecir categorías sanitarias del AQI y regresión, enfocada en la estimación del valor numérico del índice. Esta doble metodología permite evaluar el desempeño desde una óptica operativa (gestión de alertas) y analítica (precisión estadística). Ambos enfoques fueron

ejecutados con y sin la incorporación de rezagos temporales, lo que permitió cuantificar el impacto de los datos en la capacidad predictiva del sistema.

En la etapa de clasificación se entrenaron modelos de Regresión Logística, Random Forest, XGBoost y Redes Neuronales Densas (DNN). La evaluación se realizó utilizando métricas de accuracy, F1-score ponderado y AUC-ROC, considerando el desbalance de clases presente en los datos. Los mejores resultados se obtuvieron con Random Forest (régimen crítico) y XGBoost (régimen normal y global), alcanzando valores de F1-score superiores a 0,98 y AUC cercanos a 1, lo que indica una alta capacidad de discriminación entre categorías (Gráf. 4).

Para la regresión se evaluaron Regresión Lineal, Random Forest, XGBoost, DNN y modelos LSTM. Los modelos clásicos y una versión de LSTM incluyeron los rezagos temporales, mientras que la segunda versión de LSTM se entrenó con las variables originales del Dataset, para comprobar si existe una ventaja para el modelo al contar con la dependencia temporal ya establecida. La selección de modelos se basó en métricas de RMSE, MAE y R^2, segmentando el análisis por régimen de contaminación (normal, crítico y global). Los resultados muestran que la Regresión Lineal fue el modelo más preciso en los segmentos global y crítico, con RMSE aproximados de 7,1 y 8,8 respectivamente y valores de R^2 superiores a 0,99. En el régimen normal, XGBoost obtuvo el mejor desempeño, con RMSE cercano a 3,1 y $R^2 \approx 0{,}98$ (Gráf. 8).

Los modelos LSTM, a pesar de su mayor complejidad, no lograron superar a los enfoques clásicos, lo que evidencia que la dinámica del AQI puede capturarse eficazmente mediante ingeniería de variables explícitas y modelos más simples (Gráf. 14).

Impacto en el Negocio

El impacto esperado del proyecto se manifiesta principalmente en la mejora de los sistemas de monitoreo y alerta temprana de la calidad del aire. La disponibilidad de modelos predictivos precisos y confiables permite anticipar episodios críticos de contaminación, facilitando la implementación de medidas preventivas como alertas a la población, restricciones de tráfico o ajustes en actividades industriales.

Desde el punto de vista económico y operativo, el uso de modelos clásicos con alto desempeño y bajo costo computacional representa una ventaja significativa. Estos modelos son más simples de implementar, mantener e interpretar, lo que favorece su adopción en entornos productivos y sistemas automatizados. A su vez, la interpretabilidad de modelos como la Regresión Lineal y XGBoost contribuye a una mayor confianza por parte de los tomadores de decisión.

Entre los riesgos y limitaciones del proyecto se destacan la dependencia de la calidad de los datos de entrada y la disponibilidad de información histórica adicional. La presencia de errores en sensores o cambios estructurales en el entorno urbano podría afectar la capacidad de generalización de los modelos. No obstante, la metodología empleada es escalable y adaptable a otras ciudades o períodos temporales, siempre que se disponga de datos comparables.

Conclusiones y Recomendaciones

El proyecto demuestra que un análisis exploratorio riguroso y una correcta formulación del problema son determinantes para el éxito de un modelo predictivo. Los resultados evidencian que la segmentación por régimen de contaminación mejora significativamente el desempeño de los modelos y que, en este caso, los algoritmos clásicos superan a arquitecturas de deep learning más complejas.

Se concluye que la ingeniería de variables temporales y el uso de métricas adecuadas permiten capturar de forma eficaz la dinámica del AQI, logrando modelos precisos, robustos e interpretables. Asimismo, el estudio confirma que la complejidad del modelo debe estar justificada por la complejidad del fenómeno, y no al revés.

Un hallazgo fundamental fue la validación de la persistencia temporal del fenómeno en los periodos de tiempo adoptados. Dado que la calidad del aire en el entorno analizado no presenta variaciones abruptas en periodos cortos, con la incorporación de los rezagos horarios (lags) el estado inmediato anterior de la atmósfera se convierte en el predictor más robusto; lo que explica las elevadas métricas obtenidas.

Asimismo, los modelos desarrollados sin rezagos temporales podrían extrapolarse a zonas que carecen de monitoreo continuo ya que ofrecen una herramienta viable para estimar la calidad del aire en regiones donde sólo se dispone de mediciones puntuales o variables meteorológicas básicas, ampliando así el impacto potencial de la solución.

Como pasos futuros se recomienda incorporar datos de múltiples años para evaluar estabilidad temporal, explorar modelos híbridos que combinen enfoques clásicos y secuenciales, y avanzar hacia la implementación productiva de un sistema de predicción en tiempo real que soporte decisiones estratégicas en gestión ambiental y salud pública.

Código Python

El código desarrollado para este proyecto se encuentra disponible en el siguiente repositorio público de GitHub:

https://github.com/josefinaserio89/AQI-Delhi-DataScience/tree/main

Anexo: Gráficos

EDA

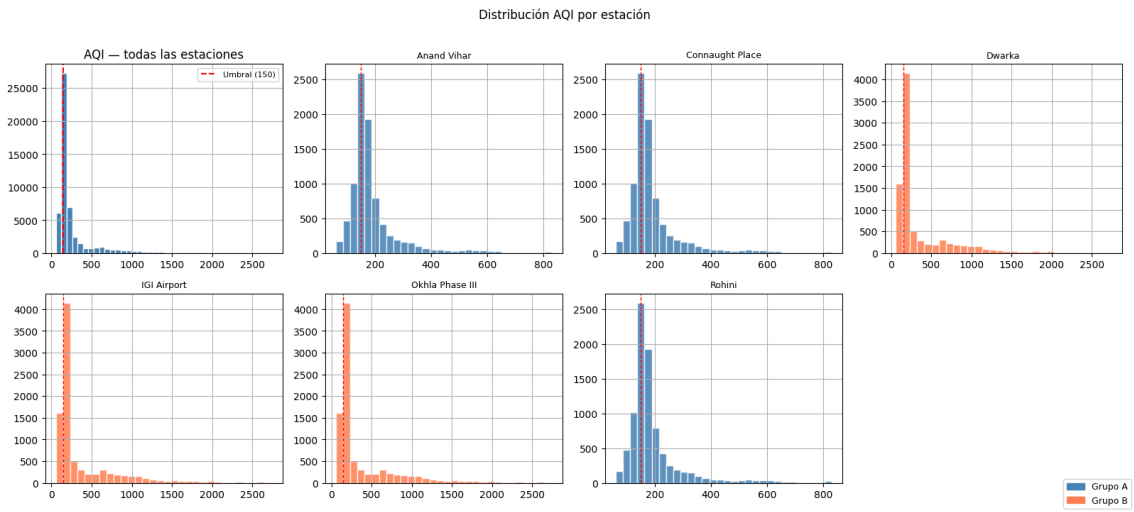

Gráfico 1 -Distribución AQI por estación: se observan dos grupos con comportamiento interno idéntico.

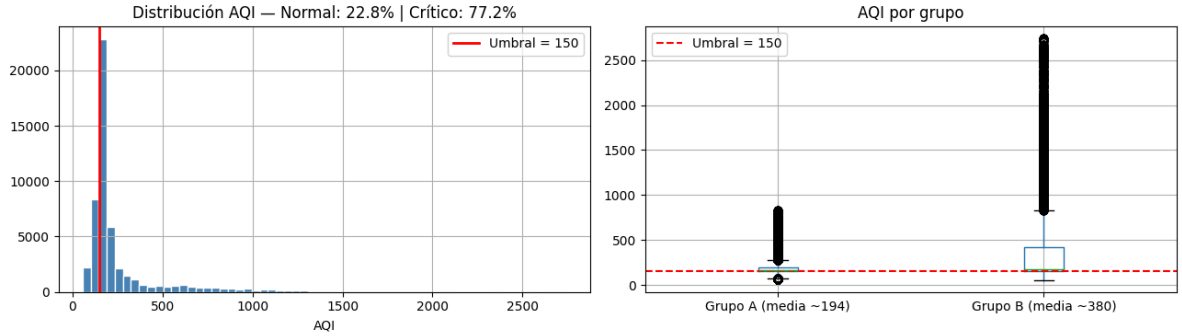

Gráfico 2 -Distribución AQI global y por grupo: se observa comportamiento no normal de la variable (importancia normalización/escalado) y diferencias por grupo.

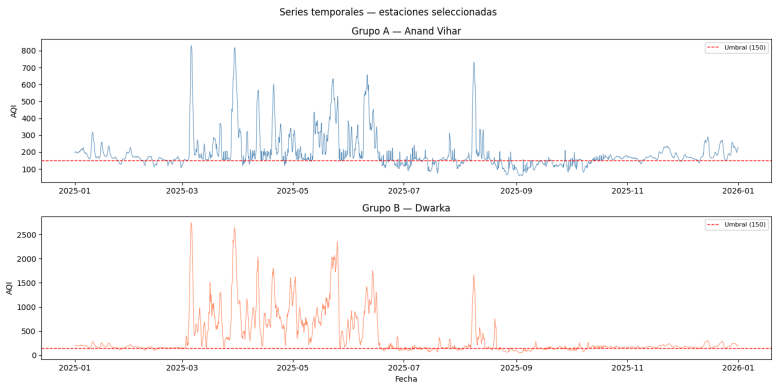

Gráfico 3 -Serie temporal de AQI por grupo: Se observan patrones similares.

ETAPA 1 — Clasificación (4 modelos × 3 segmentos)

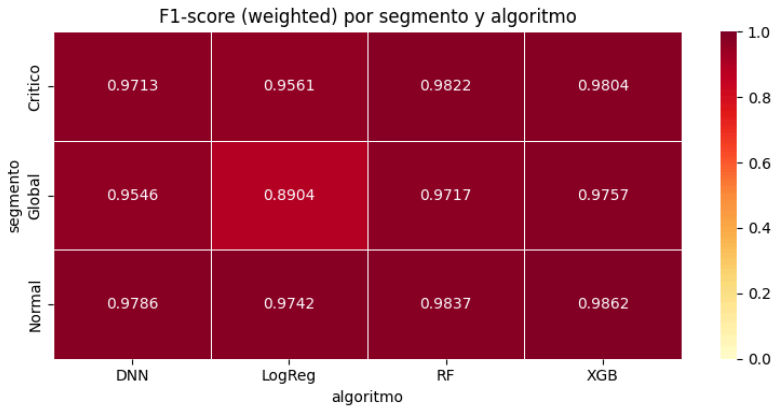

Gráficio 4 -F1-score : se observa XGBoost como mejor modelo para régimen global y normal, y RF para el régimen crítico.

FEATURES DE MAYOR IMPORTANCIA

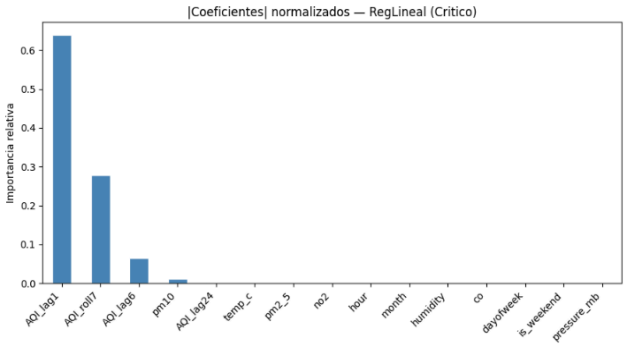

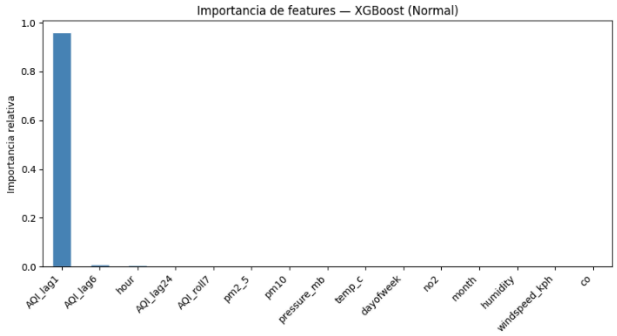

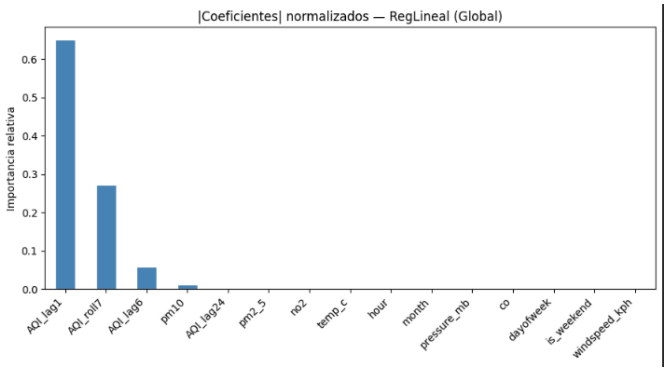

Gráfico 5,6 y 7. Importancia de features para cada régimen.

ETAPA 2 — Regresión clásica (4 modelos × 3 segmentos)

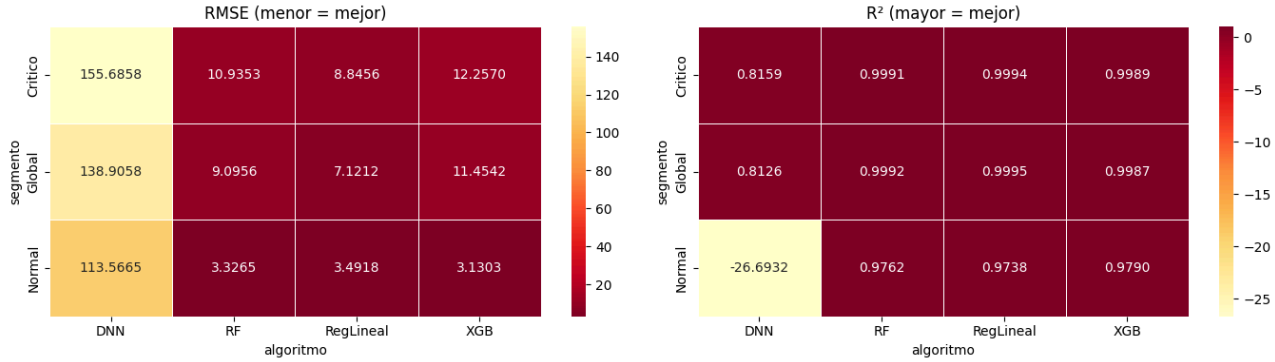

Gráfico 8 -Modelos clásicos: se observa Regresión lineal como mejor modelo para régimen global y crítico, y XGBoost para régimen normal.

ETAPA 3 — LSTM (3 segmentos: normal, crítico, global)

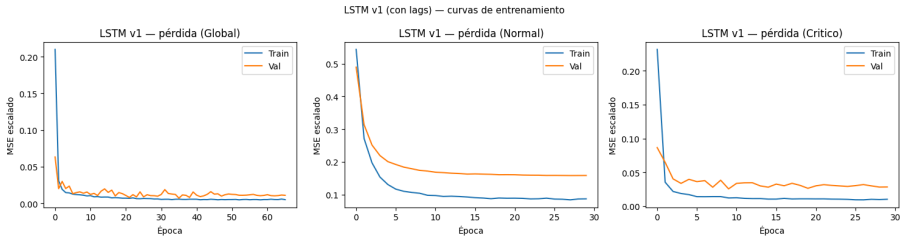

Gráfico 9 -Curvas de entrenamiento LSTM con rezagos temporales

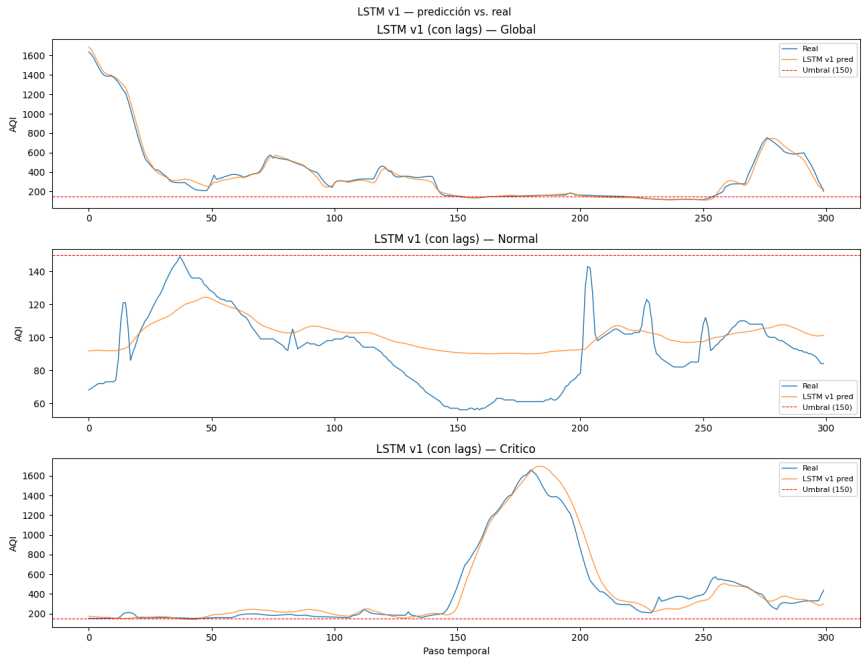

Gráfico 10 .Predicción vs real LSTM con rezagos temporales.

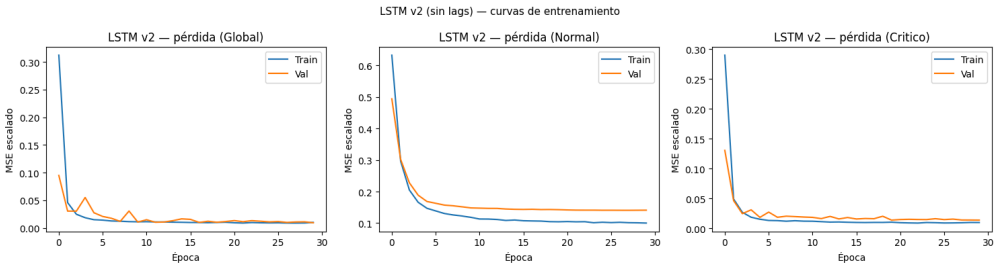

Gráfico 11 -Curvas de aprendizaje LSTM sin rezagos temporales.

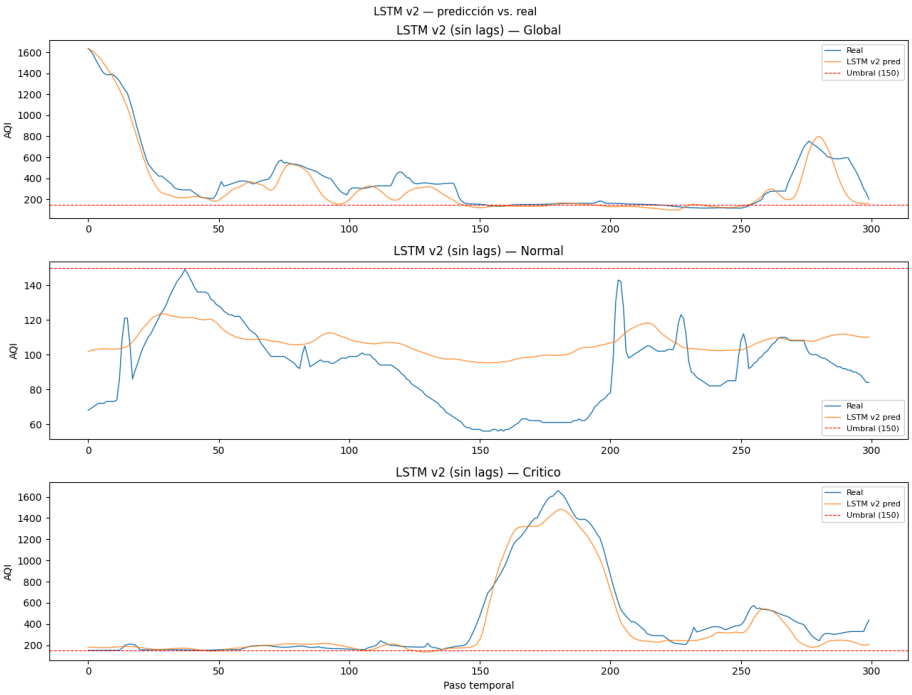

Gráfico 12 -Predicción vs real LSTM sin rezagos temporales.

COMPARACIÓN FINAL

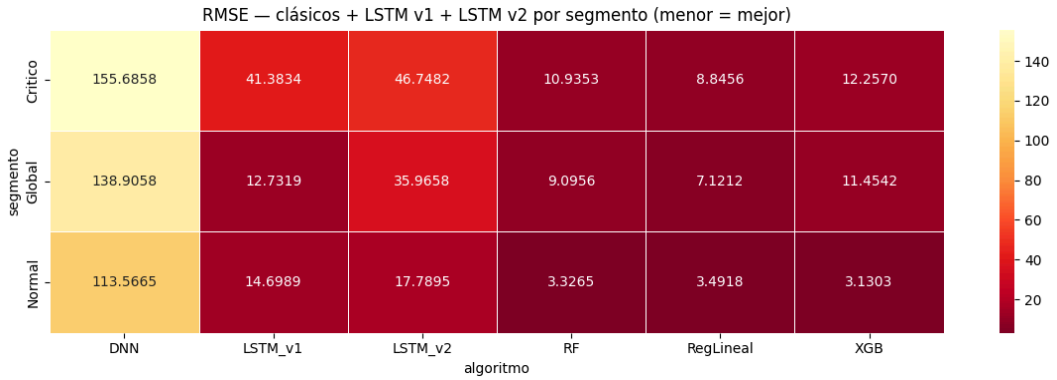

Gráfico 13 - Comparación de métricas modelos de regresión.

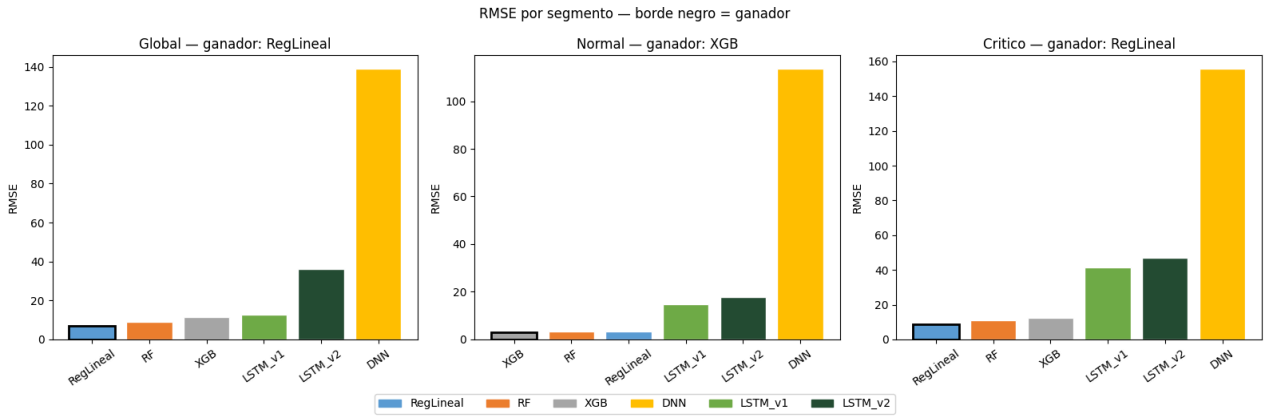

Gráfico 14 - Selección de mejor modelo para regresión.